

Sistema de Reconhecimento de Voz

Controle de Simulador de Carro com Aprendizado de Máquina

Pablo Jefte Kurt Madson

UNIVERSIDADE FEDERAL DO CEARÁ
Campus de Itapajé Jardins de Anita
Aprendizado de Máquina e Reconhecimento de Padrões

Maio de 2026

- 1 Introdução
- 2 Objetivo
- 3 Metodologia
- 4 Resultados
- 5 Resultados e Discussão
- 6 Conclusão



- Desenvolvimento de um sistema de reconhecimento de voz
- Aplicação em simulador de carro virtual
- Comandos identificados:
 - Direita, Esquerda, Voltar, Pare, Siga
- Uso de técnicas de:
 - Processamento de áudio
 - Aprendizado de Máquina

- Receber comandos de voz
- Processar sinais de áudio
- Classificar corretamente os comandos
- Controlar um carro em ambiente virtual



Pipeline do Sistema

- ① Coleta dos dados
- ② Padronização dos dados
- ③ Preparação do modelo
- ④ Transformações (FFT e STFT)
- ⑤ Geração de espectrogramas
- ⑥ Aplicação dos modelos
- ⑦ Predição dos comandos

Modelos Utilizados

Machine Learning

Random Forest

Deep Learning

CNN (Redes Neurais Convolucionais)

Padronização dos Dados

- Remoção de ruídos
 - Eliminação de interferências externas (ambiente, microfone)
 - Melhora a qualidade do sinal de áudio
 - Evita que o modelo aprenda padrões irrelevantes
- Padronização dos áudios
 - Ajuste de taxa de amostragem e duração
 - Normalização de volume
 - Garante uniformidade entre os dados
- Garantia de qualidade dos dados
 - Redução de inconsistências no dataset
 - Aumento da confiabilidade dos modelos
 - Impacto direto na acurácia da classificação

Preparação do Modelo

- Organização dos áudios
 - Separação por classes (comandos)
 - Estruturação em diretórios
 - Facilita o treinamento supervisionado
- Divisão em:
 - Treino
 - Usado para aprendizado do modelo
 - Teste
 - Avaliação da capacidade de generalização
- Extração de características (features)
 - Transformação do áudio em dados numéricos
 - Captura de padrões relevantes (frequência, energia)
 - Entrada para modelos como Random Forest



- Conversão do sinal do tempo para frequência
 - Representa o áudio como soma de frequências
 - Permite análise mais detalhada do sinal
- Identificação de padrões sonoros
 - Detecta características únicas de cada comando
 - Diferencia palavras com base na frequência
- Base para construção dos espectrogramas
 - Fundamenta a aplicação da STFT
 - Essencial para geração de Mel Spectrogramas


- Representação visual do áudio
 - Conversão do sinal em uma imagem (tempo x frequência)
 - Permite análise visual dos padrões sonoros
 - Facilita o uso em modelos de visão computacional
- Baseada na percepção auditiva humana
 - Escala Mel aproxima como o ouvido humano percebe frequências
 - Dá mais importância às frequências mais relevantes
 - Torna a representação mais realista
- Facilita o aprendizado da CNN
 - CNN trabalha melhor com dados em formato de imagem
 - Permite identificar padrões espaciais no áudio
 - Melhora a capacidade de classificação dos comandos

- CNN (Redes Neurais Convolucionais)
 - Entrada: espectrogramas
 - Representação visual do áudio
 - Permite capturar padrões complexos
 - Uso de data augmentation
 - Aumento artificial do conjunto de dados
 - Melhora a generalização do modelo
 - Reduz overfitting
- Random Forest
 - Entrada: features extraídas
 - Dados numéricos derivados do áudio
 - Representam características relevantes do sinal
 - Vantagens
 - Baixo custo computacional
 - Boa performance com poucos dados




Função de Perda (Loss)

- Erro estabiliza rapidamente após poucas épocas.
- Indica convergência precoce do modelo.
- Treinamento estável, sem oscilações bruscas.




Separação das Classes (PCA)

- O PCA reduz a dimensionalidade mantendo a variabilidade dos dados.
- As classes formam agrupamentos bem definidos.
- Baixa sobreposição indica boa qualidade das features extraídas.
- Facilita a classificação pelos modelos.



Confiança das Previsões

- Probabilidades concentradas próximas de 1.0.
- Modelo realiza previsões com alta certeza.
- Baixa ambiguidade nas classificações.
- Indica consistência e confiabilidade.



- Entrada: comando de voz
- Processamento do áudio
- Saída: ação no simulador



Resultados Esperados

- Identificação correta dos comandos
- Boa performance dos modelos
- Sistema funcional para controle do carro

- Padronização dos áudios de entrada
 - Diferença entre áudio do dataset e áudio capturado
 - Variações de volume e presença de ruídos
 - Necessidade de segmentação (fatiamento) do áudio
- Conversão dos arquivos de áudio
 - Necessidade de padronizar para formato .wav
 - Uso de conversores externos (sem uso de librosa)
 - Garantia de mesmo codec entre os arquivos
- Data Augmentation
 - Geração de variações artificiais dos dados
 - Aumento da robustez do modelo
 - Processo trabalhoso para manter qualidade dos dados

- Sistema funcional de reconhecimento de voz
- Aplicação prática em simulador virtual de um carro

Obrigado!